

EMBODIED INTELLIGENCE • TECH SHARING

VLA 大模型技术分享报告

视觉 - 语言 - 动作模型：发展轨迹、技术路线与训练部署实践

解析对象：ACT / act-plus-plus (Mobile ALOHA) • NVIDIA Isaac-GR00T N1 • Physical Intelligence openpi ($\pi0$) • Google robotics_transformer (RT-1 / RT-2)

01 发展背景与意义

02 与传统控制对比

03 技术路线与理论框架

04 训练部署全流程

05 发展趋势

具身智能技术组 • 2026 年 7 月

01

VLA 发展背景、轨迹与意义

从深度学习到基础模型：VLA 的诞生逻辑、发展脉络与核心优势

02

与传统视觉机器人控制对比

感知 - 规划 - 控制流水线 vs 端到端 VLA：架构、泛化与工程差异

03

VLA 大模型技术路线与理论框架

RT-1/RT-2、ACT、 $\pi 0$ 、GR00T N1 四条代表性路线的架构与理论剖析

04

模型训练部署全流程

数据采集→清洗→转换→增强→训练→部署→性能测试完整流水线

05

发展趋势

数据、模型、推理、评测与生态五个维度的未来演进方向

PART 01

VLA 发展背景、轨迹与意义

Vision-Language-Action：机器人学习从专用小模型走向通用基础模型

VLA 为什么会出现：三股技术洪流的交汇

大模型能力外溢

- LLM/VLM（GPT、PaLM、Gemini、LLaMA）展现出强大的开放世界语义理解与常识推理能力
- 视觉 - 语言预训练（CLIP、PaLI、SigLIP）打通了图像与文本的统一表征空间
- 自然的问题：能否让互联网级知识“长出手脚”，直接输出机器人动作？

机器人学习的数据瓶颈

- 传统强化学习 / 模仿学习任务专用、数据昂贵，换任务 / 换场景即失效
- 遥操作数据采集成本高（ALOHA 将双臂遥操作硬件降至 ~2 万美元量级）
- Open X-Embodiment 等跨机器人数据集汇聚 100 万 + 轨迹，规模法则开始在机器人领域生效

硬件与算力成熟

- 端侧算力（Jetson Orin/Thor）足以承载十亿至几十亿参数模型实时推理
- 灵巧硬件（双臂、人形、灵巧手）快速降价，具身平台多样化
- 仿真（Isaac Lab、MuJoCo）+ 合成数据管线可低成本放大真实数据

核心命题：VLA = 视觉（Vision）+ 语言（Language）→ 动作（Action）。用一个统一的大模型，接收图像观测与自然语言指令，直接生成机器人控制动作，实现“看得懂、听得懂、做得到”。

VLA 技术演进时间线（2022-2026）



演进主线：动作离散 token（RT-1/RT-2）→ 动作分块生成（ACT）→ 扩散 / 流匹配连续动作（π0、GR00T）；单一具身 → 跨具身、跨任务通用基础模型。

VLA 的战略意义、四大核心优势与当前不足

战略意义：VLA 把机器人控制从“针对每个任务写程序 / 训小模型”转变为“训练一次基础模型 + 少量微调适配”，是具身智能的 GPT 时刻的候选路径。

优势 1：语义泛化

继承 VLM 的互联网知识：能理解“把濒危动物玩偶递给我”这类训练集中从未出现的组合概念（RT-2 涌现能力评测泛化成功率约 $2 \times$ RT-1）

优势 2：端到端简化

感知、语义理解、决策、控制统一在一个网络中优化，消除模块间接口误差累积；ACT 证明端到端可完成插接、开盖等毫米级精细操作

优势 3：跨具身与规模效应

同一架构可吸收多机器人、多形态数据（OXE/GR00T 数据金字塔），数据越多能力越强，呈现类似 LLM 的 Scaling Law

优势 4：自然语言交互

任务以自然语言下达，无需重新编程；支持指令组合、多步任务分解，与上层 LLM 规划器（如 SayCan、GR00T System 2）无缝衔接

当前阶段的主要不足（与四大优势相对照）

- 数据仍稀缺昂贵：OXE 百万级轨迹 vs LLM 万亿级 token，相差 5-6 个数量级；遥操作采集人力密集，仿真存在 sim-to-real gap
- 物理泛化脆弱：换光照 / 视角 / 物体位置易失败，真实成功率约 50%-90%，距工业级 99.9%+ 仍有巨大差距；长时序任务成功率随步骤衰减
- 端到端黑箱：失败难定位（感知 / 理解 / 控制），缺乏形式化安全保证，幻觉问题从 LLM 继承，人机共处场景是硬伤
- 推理延迟与模态缺失：十亿级参数推理频率 vs 高频控制需求矛盾（ $\pi 0$ 50Hz、GR00T 双系统均为折中）；触觉 / 力觉缺失，接触密集任务能力有限
- 工程化不成熟：评测基准不统一、结果不可横向比较；失败恢复与持续学习尚在早期（ $\pi^*0.6$ RECAP 正在探索）

一句话总结：VLA 让机器人第一次拥有“通用先验”——先看懂世界、听懂人话，再学会动手，而不是从零学每一个动作。

PART 02

与传统视觉机器人控制对比

模块化流水线 vs 端到端 VLA：范式差异与工程权衡

两种范式的信息流对比

传统视觉机器人控制（模块化流水线）



特点：每个模块独立设计、独立调参；接口为人工定义的中间表示（位姿、轨迹点）；误差逐级累积，语义理解能力有限。

VLA 端到端范式



特点：像素与文本直接映射到动作；语义、几何、动力学知识隐式融合在同一组权重中；靠数据与算力换取通用性。

本质区别：传统方法“人来分解问题，机器执行”；VLA“机器从数据里学会分解问题”。

传统视觉控制 vs VLA：八个维度

对比维度	传统视觉机器人控制	VLA 大模型
系统架构	感知→规划→控制串行模块，人工定义接口	单一神经网络端到端，图像 + 语言→动作
任务定义	编程 / 示教器 / 状态机，改任务需重新开发	自然语言指令，零 / 少样本切换任务
泛化能力	限于标定场景与已建模物体，光照 / 位置变化敏感	对新物体、新指令、新场景有语义级泛化（RT-2 涌现评测约 2× RT-1）
误差特性	各模块误差累积（标定误差 + 检测误差 + 规划误差）	整体优化无接口误差，但存在分布外失效、可解释性差
数据 / 知识来源	人工建模 + CAD + 手工特征 / 专用检测模型	互联网图文预训练 + 大规模遥操作 / 仿真轨迹
开发成本	单任务开发周期长，专家依赖强；运行算力低	预训练成本高，但下游适配仅需数十 ~ 数百条演示（ $\pi 0$ /GR00T 微调）
实时性 / 确定性	毫秒级确定性控制，易做安全认证	10-50Hz 推理，需动作分块 / 蒸馏 / 量化优化；确定性与安全认证是挑战
典型代表	手眼标定 + 抓取位姿检测（GPD）+MoveIt	RT-1/RT-2、ACT、 $\pi 0$ 、GR00T N1

务实结论：两者并非取代关系——工业高精度重复场景传统方法仍占优；开放环境、长尾任务、人机交互场景 VLA 优势显著，混合架构（VLA 决策 + 传统底层控制器执行）是当前工程主流。

PART 03

VLA 大模型技术路线与理论框架

四条代表性路线：RT 系列 · ACT · $\pi 0$ · GR00T N1

VLA 的统一数学形式与三大技术流派

统一形式化：学习策略 $\pi_{\theta}(a_{t:t+H} | o_t, \ell)$

o_t ：多视角图像 + 本体感知状态； ℓ ：自然语言指令； $a_{t:t+H}$ ：未来 H 步动作块（action chunk）

流派一：自回归离散 token

- 把连续动作按维度分箱离散化为 256 个 bin 的 token
- 动作预测 = 下一个 token 预测，完全复用 LLM 训练 / 推理栈
- 代表：RT-1（专用 Transformer）、RT-2（VLM 共同微调）
- 优点：与 VLM 天然统一；缺点：精度受分箱限制、推理慢（逐 token）

流派二：生成式建模（CVAE）+ 动作分块

- CVAE 编码演示动作的多模态分布，隐变量 z 捕捉风格差异
- 一次预测 k 步动作块 + 时间集成（temporal ensembling）平滑执行
- 代表：ACT / act-plus-plus（ALOHA、Mobile ALOHA）
- 优点：高频精细控制、训练轻量；缺点：单任务为主、语言条件弱

流派三：扩散 / 流匹配连续动作

- 以扩散模型或 Flow Matching 建模连续动作分布，迭代去噪生成动作块
- VLM 骨干提供语义条件，动作专家网络负责生成
- 代表： π_0 / openpi（Flow Matching）、GR00T N1（Diffusion Transformer）
- 优点：连续高精度、多模态分布、50Hz 高频；缺点：多步去噪需推理优化

通用 VLA 一体化模型架构图




图: 通用 VLA 一体化模型架构 (来源: reports/VLA 一体化模型架构图.png)

robotics_transformer : RT-1 / RT-2 (Google DeepMind)

路线定位：动作 Token 化 + 自回归 Transformer——把机器人控制变成“语言建模”问题



RT-1 (2022) 要点

- 数据：13 个机器人 17 个月采集 13 万条轨迹、700+ 任务
- 动作空间：手臂 7 维 + 底盘 3 维 + 模式 1 维，全部离散化为 token
- 3Hz 闭环推理；已见任务成功率 97%，新任务泛化明显强于此前基线
- 意义：首次证明“大数据 + Transformer”在真实机器人上的规模收益


RT-2 (2023) 要点：VLA 概念的提出者

- 骨干：PaLI-X (55B) / PaLM-E (12B) 视觉语言模型
- 关键做法：动作 token 直接复用文本词表（如覆盖低频 token），机器人数据与互联网 VQA 数据共同微调（co-fine-tuning）
- 涌现能力：符号理解、推理链、人类识别等未训练技能迁移到操作
- 泛化评测成功率约为 RT-1 的 2 倍；证明 VLM 预训练知识可直接转化为操作能力

理论内核： $P(a|o, \ell)$ 分解为自回归 token 概率乘积 $\prod P(\text{token}_i | \text{token}_{<i}, o, \ell)$ ——机器人控制 = 条件语言建模。

act-plus-plus : ACT 动作分块 Transformer (Stanford ALOHA)

路线定位：CVAE 生成式模仿学习 + 动作分块——低成本硬件上的毫米级精细双臂操作



核心机制

- 动作分块 (Action Chunking)：一次预测未来 $k=100$ 步动作，将有效决策频率降低 100 倍，显著缓解模仿学习的复合误差 (compounding error)
- 时间集成 (Temporal Ensembling)：对同一时刻的多次重叠预测加权平均，保证动作平滑
- CVAE：隐变量 z 建模人类演示的多模态性；推理时 $z=0$ 取均值策略

工程与成果 (act-plus-plus 仓库)

- 仅需 50 条演示即可学会插线、开盖、装配等精细任务，成功率 80–90%
- Mobile ALOHA：扩展底盘动作维度，实现炒菜、擦桌、乘电梯等移动操作
- 仓库含 ACT / Diffusion Policy / VINN 三种策略实现与仿真环境 (MuJoCo)
- 局限：语言条件能力弱 (任务专用)，是“小而精”的 A (动作) 侧代表，为大 VLA 提供动作分块与高频控制的关键组件思想

理论内核： $\max_{\theta} \mathbb{E}[\log \pi_{\theta}(a_{t:t+k} | o_t, z)] - \beta \cdot D_{KL}(q(z|a, o) \parallel N(0, I))$ —— CVAE 证据下界 + 分块降低误差累积。

openpi : $\pi 0$ / $\pi 0$ -FAST / $\pi 0.5$ / $\pi^*0.6$ / $\pi 0.7$ (Physical Intelligence)

路线定位：VLM 骨干 + Flow Matching 动作专家——通用机器人基础模型的开源标杆



核心机制

- Flow Matching (流匹配)：学习速度场 v_θ ，把高斯噪声连续“流动”到专家动作，比扩散更少步数、训练更稳定
- MoE 式结构：VLM 处理图文 token，动作专家处理状态 / 动作 token，两者通过共享自注意力交互
- $\pi 0$ -FAST：用 DCT 频域压缩把动作序列高效 token 化，走自回归路线，训练提速 5×

工程与成果 (openpi 仓库)

- 预训练：10,000+ 小时、7 种机器人平台、68 类任务的自有 + OXE 混合数据
- 开源 $\pi 0/\pi 0.5$ 基座与 DROID/ALOHA/LIBERO 微调 checkpoint，提供 JAX/PyTorch 双实现
- 叠衣服、清桌面、组装纸箱等长时程灵巧任务达到 SOTA； $\pi 0.5$ 强化开放世界泛化（进入陌生家庭做清洁）
- 微调门槛：1-20 小时数据即可适配新任务；LoRA 微调单卡 A100 可行

理论内核： $\min_{\theta} \mathbb{E} \| v_\theta(a^\tau, o, \ell, \tau) - (a - \epsilon) \|^2$ ， $a^\tau = \tau \cdot a + (1-\tau) \cdot \epsilon$ —— 条件流匹配损失，一次生成整段连续动作块。

Isaac-GR00T : GR00T N1 / N1.5 / N1.7 (NVIDIA)

路线定位：双系统认知架构 + 数据金字塔——面向人形机器人的开放基础模型与全栈生态



数据金字塔 (Data Pyramid)

- 塔基：海量网络视频与人类第一视角数据（学习世界知识与操作先验，用潜在动作 / 逆动力学标注伪动作）
- 塔身：仿真合成数据（Isaac Lab / GR00T-Dreams 世界模型生成轨迹）
- 塔尖：真实机器人遥操作数据（最贵最少，锚定真实动力学）

工程与成果 (Isaac-GR00T 仓库)

- N1 为 2B 级开放权重模型；N1.5 改进 VLM 对齐与 FLARE 目标，语言跟随率 46.6%→93.3%（GR-1 类人形评测）
- 跨具身支持：GR-1/G1 人形、单臂 / 双臂等，通过具身特定投影层 + 新具身微调接入
- 全栈生态：Isaac Lab 仿真、OSMO 训练编排、Jetson Thor 端侧部署、TensorRT 推理优化

理论内核：Kahneman 双系统认知（System1 直觉快 / System2 推理慢） × 流匹配动作生成 × 异构数据统一训练。

2025-2026 前沿更新： $\pi^*0.6$ · $\pi 0.7$ · GR00T N1.7

$\pi^*0.6$ （2025.11 · Physical Intelligence）— VLA 从自身经验中学习

RECAP 三阶段训练：专家示范（模仿）→ 人工实时纠正（教练式干预）→ 自主 RL 练习（价值函数标注正 / 负样本，无需动作对数概率）。叠衣、意式咖啡、纸箱组装等困难任务吞吐量提升 2 倍以上、失败率约减半，可连续自主运行 13 小时 + —— 标志 VLA 从纯模仿学习迈入自我改进阶段（"RL is back"）。

$\pi 0.7$ （2026 · Physical Intelligence）— 可组合泛化与可控提示

把已学技能像语言模型组合概念一样 " 混搭 " 解决从未训练过的新任务（少量数据即可操作新厨电并完成烹饪）；支持多模态可控提示：自然语言 + 视觉子目标图像 + 任务元数据（速度 / 风格约束）；零样本跨具身迁移到未见过的硬件平台执行叠衣等任务；50Hz 实时控制，单一通用模型达到或超越专用微调模型水平。

GR00T N1.7（2026 · NVIDIA）— 骨干升级与完全商用开源

骨干升级为 Cosmos-Reason2-2B（Qwen3-VL）+ Diffusion Transformer 动作头，延续双系统架构；预训练数据跃升至 3.2 万小时真实人类第一视角视频 + 8 千小时仿真；实现指尖级灵巧、接触密集小件装配与双臂协同（Unitree G1、AGIBot Genie 实测）；首次以 Apache 2.0 + 商用许可完全开放权重与代码，完善 ONNX/TensorRT 部署链路，FANUC、ABB、LG 等厂商已开始采用。

共同趋势：基础模型底座之上，前沿正转向经验强化学习（RECAP）、技能组合泛化（ $\pi 0.7$ ）与开放商用生态（N1.7）——与 PART 05 五大趋势相互印证。

四大代表模型关键参数一览

维度	RT-1 / RT-2	ACT (act-plus-plus)	$\pi 0$ (openpi)	GR00T N1/N1.5
机构 / 时间	Google DeepMind 2022 / 2023	Stanford 2023 / 2024	Physical Intelligence 2024-2025	NVIDIA 2025
模型规模	35M / 12B-55B	~80M	3B + 300M 动作专家	~2B （VLM+DiT）
视觉 / 语言骨干	EfficientNet+USE / PaLI-X · PaLM-E	ResNet-18 （无语言骨干）	PaliGemma (SigLIP+Gemma)	Eagle-2 (SigLIP-2+SmolLM2)
动作生成	离散 token 自回归	CVAE + 动作块回归	Flow Matching 连续动作块	DiT 流匹配去噪动作块
控制频率	3 Hz	50 Hz （块内）	50 Hz （块 50 步）	~120 Hz （System1）
训练数据	13 万轨迹 / 700 任务； RT-2 加网络图文	每任务 ~50 条人工演示	1 万 + 小时自有 + OXE	真实 + 仿真 + 人类视频 数据金字塔
定位	验证规模化与语义涌现	低成本精细双臂操作	通用操作基础模型	人形机器人基础模型 + 生态

PART 04

模型训练部署全流程

数据采集 → 清洗 → 转换 → 增强 → 训练 → 部署 → 性能测试

VLA 从数据到落地的七阶段流水线



🔄 数据飞轮闭环：⑦ 测试中发现的失败案例回流到 ① 定向补采 / ④ 定向增强，持续迭代（ $\pi 0$ 、GR00T 均采用此闭环）

阶段	关键活动	典型工具 / 实践（四个开源项目中的对应）
①-④ 数据工程	占整体工作量 60% 以上；决定模型上限	ALOHA 遥操作、Isaac Lab 仿真、GR00T-Dreams 合成、LeRobot/RLDS 数据格式
⑤ 训练	两阶段：跨具身预训练 + 目标平台后训练	openpi train 脚本（JAX/PyTorch, FSDP）、Isaac-GR00T gr00t_finetune（LoRA/ 全参）
⑥ 部署	策略服务器 - 客户端解耦，端侧优化	openpi serve_policy + websocket 客户端；GR00T TensorRT/Jetson 部署脚本
⑦ 测试	离线指标 + 仿真基准 + 实机 A/B	LIBERO/SimplerEnv 基准、act-plus-plus 仿真评测、真实成功率统计

数据采集 → 清洗 → 转换 → 增强

① 数据采集

- 遥操作：ALOHA 双臂关节映射、VR 手柄、外骨骼；同步录制多视角 RGB(-D)、关节状态、动作、语言标注
- 仿真采集：Isaac Lab / MuJoCo 脚本化专家 + 域随机化批量生成
- 非机器人数据：人类第一视角视频、网络图文（塔基数据）
- 规范：统一坐标系与单位、时间戳硬同步、每条轨迹附任务指令

② 数据清洗

- 剔除失败 / 中断 / 超时轨迹（或保留并标注用于失败感知训练）
- 过滤传感器异常：丢帧、图像过曝 / 遮挡、关节读数跳变（速度 / 加速度阈值检测）
- 去重与均衡：近重复轨迹去重，任务 / 物体 / 场景分布重采样
- 语言标注质检：指令 - 行为一致性抽检，LLM 辅助重写多样化指令


③ 数据转换

- 统一 schema：observation(images/state) + action + language + episode 元数据
- 目标格式：LeRobot Dataset（GR00T N1.5 / openpi 支持）、RLDS/TFDS（RT-X/OXE）、HDF5（act-plus-plus）
- 动作空间对齐：关节角 vs EEf 位姿、绝对 vs 增量、归一化统计量（mean/std 或 quantile）落盘
- 跨具身映射：GR00T 具身投影头 / $\pi 0$ 动作维度 padding

④ 数据增强

- 视觉增强：随机裁剪、颜色抖动、亮度对比度、相机 jitter（RT-1/ACT 常规配置）
- 仿真域随机化：纹理、光照、物体位姿、动力学参数随机
- 合成放大：GR00T-Dreams 世界模型由少量真实轨迹生成大量新场景轨迹；DexMimicGen 自动扩增装配演示
- 语言增强：同义指令改写、多语言指令，提高指令鲁棒性

两阶段训练：跨具身预训练 + 目标平台后训练



关键训练配置（以 openpi / GR00T 为参照）


- 损失函数：流匹配 MSE ($\pi 0$ /GR00T) 或 token 交叉熵 (RT 系/ $\pi 0$ -FAST) ; ACT 为 L1 重建 + KL
- 归一化：动作 / 状态按数据集统计量归一化，微调新平台必须重新计算 norm stats
- 冻结策略：小数据微调可冻结 VLM 只训动作专家 / 投影层；数据充足全参微调效果更佳
- 算力参考： $\pi 0$ LoRA 微调单卡 A100/4090(量化) 可行，全参需多卡 80GB ; GR00T N1.5 微调支持单节点多 GPU

工程要点

- 数据加载是瓶颈：视频解码 / 图像预处理放 GPU 或 DALI , 多进程 prefetch
- 混合比例调度：真实 : 仿真 : 视频数据配比是关键超参 (GR00T 数据金字塔按阶段调整)
- 训练监控：除 loss 外必须跟踪动作 MSE 分维度曲线与验证集 rollout 视频
- 复现基线：先在 LIBERO/ALOHA-sim 等公开基准复现官方结果，再引入自有数据

经验法则：预训练决定“会不会”，后训练决定“好不好”；微调数据质量 > 数量，50 条高质量演示常胜过 500 条噪声演示。

从 checkpoint 到机器人：推理服务与端侧优化



推理优化手段

- 量化: FP16/BF16 → INT8/FP8 (TensorRT); $\pi 0$ 支持 4090 级消费卡推理
- 减少去噪步数: 流匹配 10 步内收敛; 蒸馏到更少步或一步生成
- 动作分块摊销: 一次推理输出 50 步动作, 网络 2-5Hz 调用即可支撑 50Hz 控制
- KV cache / 图优化: VLM 前缀缓存, CUDA Graph 固化推理图

部署形态选择

- 云 / 边服务器 + 局域网: 开发迭代快, 注意网络抖动 (openpi 默认形态)
- 端侧一体化: Jetson AGX Orin/Thor 承载 GR00T N1, 离线可用、延迟确定
- 混合: System2 云端大模型规划 + System1 端侧高频执行
- 版本管理: 模型 + norm stats + 预处理配置整体打包, 灰度发布可回滚

延迟预算示例 (50Hz 控制): 图像采集 5ms + 传输 5ms + 推理 60ms (摊销到 50 步 $\approx 1.2\text{ms}/\text{步}$) + 控制器 1ms — 动作分块是实时性的关键。

三级评测体系：离线指标 → 仿真基准 → 实机验证

L1 离线评测

分钟级 · 每次训练

- 动作 MSE / L1（分维度）、token 准确率
- 验证集 rollout 可视化对比人类演示
- 作用：快速筛掉明显失败的 checkpoint，但离线指标与真实成功率相关性有限

L2 仿真基准

小时级 · 每个候选

- LIBERO（openpi 提供微调基线）、SimplerEnv、RoboCasa、act-plus-plus 内置双臂仿真任务
- 批量并行 rollout 统计成功率、SPL、平均完成时间
- 域随机化下的鲁棒性扫描（光照 / 位姿 / 干扰物）

L3 实机测试

天级 · 上线前

- 标准化评测协议：固定任务集 × N 次重复（ ≥ 10 ）× 多初始条件，盲测 A/B 对比
- 指标：成功率、子任务完成率、干预次数 / 小时、执行时长、碰撞 / 安全事件
- 失败归因分析 → 回流数据飞轮定向补采

测试要点：① 仿真高分 $\neq$ 实机可用，sim-to-real gap 必须用 L3 校准；② 评测集与训练集严格隔离（新物体 / 新位置 / 新指令三档泛化）；③ 报告置信区间而非单次成功率；④ 长尾失败案例库是最宝贵的资产。

PART 05

发展趋势

VLA 走向何方：数据、模型、推理、评测与生态

五大趋势展望

① 数据：从遥操作走向“万物皆数据”

人类视频学习（GR00T 塔基）、世界模型合成数据（GR00T-Dreams、Cosmos）、自主采集与 RL 自我改进（ $\pi 0.5 + RL$ ）将大幅摊薄真实遥操作成本；数据配比与质量评估成为核心 know-how

② 模型：分层双系统 + 更强推理

System2（VLM/LLM 推理规划）+ System1（高频动作专家）成为共识架构；链式思维（ECoT）、世界模型预测（V-JEPA 类）注入策略；模型规模在 2B-10B 区间寻找端侧最优解

③ 动作生成：流匹配成为主流，走向实时

从离散 token → 扩散 → 流匹配的收敛趋势明显（ $\pi 0$ 、GR00T 均选择 FM）；蒸馏 / 一步生成、异步推理（Real-Time Chunking）解决高频实时性

④ 评测与安全：从 demo 走向标准

统一基准（LIBERO、SimplerEnv、RoboArena 类实机联评）与第三方评测兴起；可解释性、失效预测、安全认证成为商用前置条件

⑤ 生态：开源基座 + 垂直微调的产业格局

openpi、GR00T、LeRobot 形成“机器人界的 LLaMA 生态”；上游卖基座与算力（NVIDIA 全栈），中游做具身平台适配，下游做场景微调与数据服务

VLA 发展趋势总览图

闭环优化的技术实现



强化学习 (RL) - 奖励驱动

基于任务成败的“奖励信号”动态调整模型参数，引导机器人倾向选择高收益动作。



模仿 + 强化 - 混合策略

先通过模仿学习快速掌握基础任务框架，再结合强化学习进行后续的精细化优化与微调。



世界模型 (World Models) - 预演决策

模型在虚拟空间中进行多次推演与路径规划，筛选最优解后执行，大幅降低物理试错成本。



持续学习框架：打破任务边界，持续从新经验中迭代模型，适应动态变化的生产环境。

图：VLA 发展趋势总览（来源：reports/VLA 发展趋势.png）

WAIC 具身智能圆桌论坛纪要：三道物理墙与产业路线之争

① 三道物理墙：具身智能规模化的核心阻碍（全场共识）

数据墙：真机交互数据成本高、无法批量爬取；表征墙：机型数据不互通、缺少通用物理表征、跨设备泛化差；闭环墙：实体试错成本高、反馈慢、数据飞轮难以快速迭代——无法复刻 LLM 的 scaling 路径，需以世界模型仿真 + 多机集群采集 + 数据回流闭环统一破局

② 数据获取路径：单一来源不足，多类数据混合成共识

PI 主打规模化真机采集；佐治亚理工押注人类第一视角 Egocentric 数据（对齐方案尚无标准）；Genesis 用仿生手套低成本采集；Dyna 采用三层金字塔（互联网视频打底 + 真机数据 + 产线失败回流，20 万小时预训练、新任务 1-2 小时微调）；清华主张互联网视频预训练专属具身基座——真实部署回流的失败样本价值最高

③ 模型架构路线：VLA 与世界模型不对立，长期走向融合

PI：VLA+ 世界模型融合，生成未来画面提升长程规划；Dyna：WAM 世界动作模型主导高频操作、规划模型负责长周期任务；腾讯：认知规划 / 感知动作 / 电机控制三层 Agent 架构；智元：VLA 与世界模型同步迭代，终局为 WRAM + 分布式真机强化学习；评判标准归结为数据学习能力、跨场景泛化与推理速度

④ 企业路线选择：全栈自研 vs 纯 AI 大脑，无优劣之分

智元走全栈自研（硬件限制模型上限，自研可优化端云协同与量产成本）；PI/ 腾讯走纯算法路线（先用通用机械臂搭数据底座、避开硬件重资产赛道）；Sunday 折中（低成本夹爪 + 少量硬件实现大部分操作，当前瓶颈在上层 AI 模型而非硬件手爪）

⑤ 对本报告的启示

论坛结论与前述五大趋势互相印证：数据金字塔与回流闭环（对应趋势①）、分层双系统与世界模型融合（对应趋势②）、统一评测标准缺失（对应趋势④）仍是 VLA 走向规模化落地必须跨越的门槛

总结与讨论

1. 范式确立

VLA 已从概念（RT-2, 2023）走到可用开源基座（ $\pi 0$ 、GR00T N1, 2024-25）：VLM 骨干 + 流匹配动作专家 + 动作分块是当前最优配方

2. 四个项目的互补启示

RT 系证明规模与语义涌现；ACT 提供高频精细控制与低成本数据采集范式； $\pi 0$ 给出通用基座 + 微调的完整工程栈；GR00T 展示数据金字塔与全栈生态打法

3. 工程主线

数据工程占 60% 以上工作量；两阶段训练（预训练 + 后训练）；动作分块摊销推理延迟；三级评测 + 数据飞轮闭环持续迭代

4. 理性判断

VLA 与传统控制是互补而非替代；泛化、安全、实时性仍是落地三大挑战；建议以开源基座（openpi/GR00T）+ 自有场景数据微调作为切入路径

参考项目：github.com/MarkFzp/act-plus-plus · [NVIDIA/Isaac-GR00T](https://nvidia.github.io/Isaac-GR00T) · [Physical-Intelligence/openpi](https://physicalintelligence.com/openpi) · [google-research/robotics_transformer](https://google-research.github.io/robotics_transformer)

谢谢 · Q & A

VLA 大模型技术分享报告 · 具身智能技术组