

EMBODIED INTELLIGENCE • TECHNICAL REPORT

VLA (Vision-Language-Action)

模型结构深度技术解析

从行为克隆、动作 Token 到 Flow Matching 与开放世界泛化

VLA = VLM 语义先验 + 动作生成模型 + 异构数据 +
闭环执行

机器人具身智能技术分享会
技术总结报告 • 2026 年 7 月

目录与报告主线

1. VLA 的问题定义与系统边界
2. 技术演进：BC $\rightarrow$ ACT $\rightarrow$ RT-1 $\rightarrow$ 现代 VLA
3. VLA 通用结构：视觉、语言、状态与动作
4. 动作生成路线：回归、Token、Diffusion、Flow
5. π_0 ：VLM 与 Action Expert 的协作
6. $\pi_{0.5}$ ：混合动作表示、层级推理与 Co-training
7. GR00T：Flow-DiT 与显式跨本体条件化
8. 主流模型横向比较
9. 数据、训练、闭环执行与部署
10. 评估体系、瓶颈和未来趋势

递进逻辑：先解决“动作怎么学”，再解决“视觉和语言怎么统一”，继而解决“连续动作如何高质量生成”，最后解决“如何跨任务、跨场景、跨本体泛化”。

执行摘要

VLA 模型将视觉观测、自然语言任务与机器人状态映射为可执行动作，是连接通用多模态认知与物理控制的核心技术层。其基本目标为：

$$\pi_{\theta}(I_{t-k:t}, q_{t-k:t}, \ell) \rightarrow a_{t:t+H}$$

其中 I 是多相机观测， q 是机器人本体状态， ℓ 是语言指令， a 是未来 H 步动作序列。现代 VLA 的性能不只由 VLM 参数量决定，而取决于四个共同因素：

语义主干

利用视觉语言预训练理解物体、场景、指令和空间关系。

动作表示

连续回归、离散 Token、Diffusion 或 Flow Matching 决定控制精度与实时性。

数据配方

目标机器人、跨本体、网页语义、高层子任务和语言示范提供互补知识。


闭环系统

Action Chunk、重规划频率、低层控制器和安全过滤决定真实部署表现。

核心判断：VLA 不是“VLM 后面接一个机械臂输出头”，而是语义表征、动作分布、时序闭环和机器人接口的联合设计。

1. VLA 的问题定义与系统边界

1.1 从模块化机器人到端到端策略



传统系统可解释且容易施加硬约束，但存在误差级联、人工技能库维护成本高、复杂接触难建模、新场景泛化弱等问题。VLA 将多级管线压缩为条件策略，通过示范数据直接学习从语义观测到动作的映射。

1.2 VLA 必须同时解决的五个问题

- 1. **任务语义**：理解“清理厨房”等开放指令。
- 2. **视觉落地**：将“盘子”“抽屉”等语言概念定位到当前图像。
- 3. **动作生成**：输出关节、末端、夹爪、底盘或躯干控制量。
- 4. **长时序**：维持子任务进度，完成多分钟、多阶段行为。
- 5. **泛化**：适应新物体、新布局、新任务组合和新机器人本体。

1.3 VLA 与底层控制器的关系

VLA 通常输出目标位姿、关节目标或底盘速度，低层仍由 PD、位置或速度控制器跟踪。VLA 负责“做什么、向哪里运动”，控制器负责“如何稳定到达目标”。因此端到端学习并不意味着取消关节限位、急停和碰撞保护。

2. 技术演进：BC → ACT → RT-1 → 现代 VLA

2.1 Behavioral Cloning：单步动作拟合

$$L_{BC} = E_{(o,a) \sim D} [\| a - \pi_{\theta}(o) \|^2]$$

行为克隆实现简单，但单步回归容易产生抖动；多解任务可能输出“平均动作”；部署状态逐步偏离专家数据后误差持续累积。

2.2 ACT：Action Chunk 与潜变量

ACT 一次输出未来动作段，而不是下一步动作：

$$\pi_{\theta}(o_t) \rightarrow \hat{a}_{t:t+H}$$

其 DETR 风格查询对应未来动作槽位，CVAE 潜变量描述同一观测下的多种合理轨迹，训练目标为：

$$L_{ACT} = L_{action} + \beta \cdot KL(q_{\phi}(z|o,a) \| p(z))$$

ACT 还可对不同时刻针对当前步的预测进行 Temporal Aggregation，缓解动作 chunk 边界跳变。ACT 本身没有语言输入，严格说不是 VLA，但奠定了多相机融合、动作分块和闭环执行等基础。

2.3 Mobile ALOHA：从双臂扩展到全身动作

$$a_t = [a_{left}, a_{right}, v, \omega] \in R^{16}$$


Mobile ALOHA 将 14 维双臂关节与夹爪动作和 2 维底盘速度直接拼接，证明统一向量动作可以支撑双臂移动操作。其另一关键发现是：静态 ALOHA 数据虽然没有底盘动作，但补零后与移动数据共同训练，仍可提供通用抓取与接近物体的运动先验。

启示：异构但相关的数据不必与目标机器人完全同分布，只要共享视觉、语义或动作结构，就可能产生正迁移。

2.4 RT-1：把动作变成 Token

RT-1 将连续动作每一维量化到有限词表，再由 Transformer 自回归预测：

$$\tau_{t,d} = \text{Quantize}(a_{t,d}), \quad L = -\sum \log p_{\theta}(\tau_{t,d} | I, \ell, \tau_{<})$$



这一转变让机器人控制可以复用语言模型的序列训练工具，但量化误差和逐 Token 解码延迟限制了精细、实时的连续控制。

3. 现代 VLA 的通用结构

3.1 四层抽象

层级	典型输入/模块	作用
输入层	多视角 RGB、语言、状态、短历史	提供环境、任务和本体条件
语义主干	Vision Encoder、LLM/VLM、跨模态注意力	理解场景、物体与任务关系
动作策略层	Action Token Head、Diffusion/Flow Expert	将语义条件转换为动作分布
执行层	Action Chunk、重规划、PD/位置控制、安全过滤	形成实时闭环并满足物理约束

3.2 三种多模态融合方式

语言调制视觉

代表 RT-1。FiLM 使用语言生成缩放和平移参数： $F' = \gamma(\ell) \odot F + \beta(\ell)$ 。轻量但深层语义交互有限。

统一多模态 Token

图像、文本和状态被映射为共同序列。语义统一、可直接利用大规模 VLM，但计算量较大。

VLM + Action Expert

代表 π_0 、 $\pi_{0.5}$ 、GR00T。大主干负责语义，小动作专家专门负责高频连续控制。

显式层级推理

先生成语义子任务，再以子任务为条件生成动作，降低长时域控制难度。

3.3 为什么动作专家逐渐成为主流

VLM 适合抽象语义与开放词汇理解，而连续控制要求高频、低延迟、强状态敏感和细粒度轨迹一致性。动作专家把两类需求隔离：既继承 VLM 的知识，又避免整个大模型反复参与每一步连续去噪。

4. 动作生成路线：真正的结构分水岭

路线	代表	训练目标	优势	局限
连续回归	BC、ACT	L1/L2, ACT 加 KL	简单、单次前向、低延迟	多峰动作易平均
离散 Token	RT-1、OpenVLA、 $\pi 0$ -FAST	交叉熵	与 LLM 训练统一、稳定扩展	量化误差、自回归较慢
Diffusion	Diffusion Policy	噪声或数据预测	表达多模态轨迹、适合 Chunk	多步去噪成本
Flow Matching	$\pi 0$ 、 $\pi 0.5$ 、GR00T	速度场 MSE	连续、高精度、可少步积分	训练与部署更复杂
混合式	$\pi 0.5$ 论文系统	Token CE + Flow MSE	兼顾训练吞吐与实时动作	两阶段配方复杂

4.1 Flow Matching 的数学直觉

Flow Matching 学习一条将动作分布与高斯噪声分布连接起来的连续速度场。以 $\pi 0$ 的约定为例：

$$x_t = t\varepsilon + (1-t)a, \quad u_t = \varepsilon - a$$

$$L_{\text{flow}} = E[\| v_{\theta}(x_t, t, c) - u_t \|^2]$$

推理从噪声开始，使用 Euler 或更高阶求解器沿速度场积分至动作。不同实现可能交换噪声端和动作端，造成目标速度符号相反，但本质等价。

4.2 为什么 Action Chunk 很重要

- 并行预测未来轨迹，减少逐步推理开销；
- 轨迹内部连续性强于独立单步预测；
- 允许只执行前几步并重新观测，兼顾效率和闭环纠错；
- 动作生成模型可以直接学习多峰轨迹分布。

5. π_0 : VLM 与 Flow Action Expert

5.1 总体结构



π_0 使用 SigLIP 编码图像，PaliGemma/Gemma 建模视觉语言上下文，并配置较小的 Gemma Action Expert。典型开源配置为 2B 语义主干和约 300M 动作专家。

5.2 Prefix / Suffix 分离

- **Prefix:** 图像、语言等语义上下文，可在多步 Flow 积分中缓存 KV。
- **Suffix:** 机器人状态、噪声动作、时间条件和 Action Expert token，每次积分更新。

该设计降低了连续去噪过程重复运行视觉语言主干的成本，同时维持动作对语义表示的条件依赖。

5.3 训练与采样

训练时随机采样 Flow 时间，构造噪声动作和目标速度场；推理时先计算并缓存 Prefix，再在 Action Expert 中迭代更新整个动作 Chunk。相比逐动作维度自回归，Flow 能并行处理所有动作时间步和维度。

结构价值： π_0 的重点不是“更大的 VLM”，而是把预训练语义能力与连续动作生成解耦，并通过注意力重新连接。

6. $\pi 0.5$: 层级推理、混合动作表示与异构 Co-training

6.1 从任务指令到语义子任务

$\pi 0.5$ 论文系统联合建模文本子任务和低层动作：

$$\pi_{\theta}(a, \ell | o, \ell) = \pi_{\theta}(a | o, \ell) \cdot \pi_{\theta}(\ell | o, \ell)$$

例如总体指令是“清理厨房”，模型先产生“拿起盘子”，再以当前图像和该子任务为条件生成连续动作。高层低频运行，低层高频输出 Action Chunk。

6.2 两阶段训练

阶段	动作表示	数据	目的
Pre-training	FAST 离散动作 Token	MM、ME、CE、HL、WD	高吞吐统一学习机器人动作、文本、框和网页语义
Post-training	Token + Flow Action Expert	MM、ME、HL、WD、VI	专门化移动操作、保留文本能力并获得实时连续控制

联合目标可概括为：

$$L = L_{\text{token}} + \alpha \cdot L_{\text{flow}}$$

6.3 数据类型及其作用

缩写	数据来源	主要贡献
MM	多环境移动机器人	目标本体、移动操作和真实长任务
ME	多环境静态机器人	更广场景和通用操作技能
CE	实验室跨本体数据	多任务动作先验
HL	高层子任务标注	任务分解与长时域推理
WD	网页图文、VQA、定位	开放物体语义和 OOD 识别
VI	人类语言示范	将高层选择对齐到低层策略能力

6.4 为什么“FAST 训练、Flow 执行”

FAST 动作 Token 可以与文本和视觉任务统一进行 next-token prediction，训练稳定且吞吐高；但自回归动作解码不利于实时控制。Flow Expert 则并行生成精细连续 Chunk，适合在线执行。混合路线本质是：

离散 Token 负责规模化知识学习，连续 Flow 负责高质量实时控制

6.5 Attention 隔离

- 图像、Prompt、State 构成共享 Prefix；
- FAST Token 看到 Prefix 和此前 FAST Token；
- Action Expert 看到 Prefix 和自身动作 embedding；
- Action Expert 不看 FAST Token，避免两种动作表示的信息泄漏；
- 信息从 VLM 单向流向 Action Expert。


6.6 关键实验结论

- 训练环境数量增加时，新环境任务进度和语言跟随持续提升；
- 去掉 ME 或 CE 会明显降低任务表现，说明跨本体迁移不可替代；
- WD 对一般动作任务影响可能不显著，但对 OOD 物体和高层策略很重要；
- HL 数据即使不在运行时显式输出子任务，也能改善低层策略；
- 通用大模型零样本规划不如用机器人数据适配后的高层策略。

开源边界：openpi 可验证 $\pi 0.5$ 的离散状态输入、AdaRMS 时间注入和 Flow Head；论文中的完整高层推理、数据配比及两阶段训练系统并未以单一脚本完整公开，报告中应区分论文系统与仓库实现。

7. GR00T: Flow-DiT 与显式跨本体条件化

7.1 总体结构



当前 GR00T N1.7 实现使用视觉语言主干提取上下文，使用 Flow-Matching DiT 动作头生成连续动作，并以本体 ID 选择本体专属投影参数。

7.2 Flow 训练

$$x_t = (1-t)\varepsilon + ta, \quad u_t = a - \varepsilon$$

$$L = E[M \odot \|v_\theta(x_t, t, c) - u_t\|^2]$$

Mask 用于忽略不同机器人补齐后的无效动作维度。推理使用固定步数 Euler 更新，默认配置强调少步实时去噪。

7.3 Embodiment Conditioning

$$y = W_e x + b_e, \quad e = \text{Embodiment ID}$$

与单纯 Padding 不同，Category-Specific Linear/MLP 为不同机器人分配专属输入和输出投影，使统一主干能够共享语义和轨迹知识，同时保留各本体动作含义。

7.4 AlternateVLDiT

动作 DiT 区分图像 Token 和非图像 Token，并在不同 Block 中交替进行视觉/语言条件注意力，减少海量视觉 Token 对控制信息的稀释。

7.5 与 π_0 和 RT-1 的区别

- 与 π_0 相同：都采用 VLM + 连续 Flow 动作专家；
- 与 π_0 不同：主干模型不同，GR00T 的本体专属参数化更显式；
- 与 RT-1 不同：RT-1 是离散动作 Token 自回归，GR00T 是连续 Chunk 的速度场生成。

8. 主流 VLA 模型横向比较

模型	语义/视觉主干	动作表示	时序输出	高层推理	跨本体路径
ACT	ResNet + DETR	连续回归	Chunk	无	任务专用
RT-1	EfficientNet + FiLM	离散 Token	短序列	隐式	固定本体
RT-2 / OpenVLA	大型 VLM	离散 Token	Token 序列	隐式语义	统一 Token/适配
Octo	Transformer Policy	连续 Chunk	Chunk	语言条件	Padding + Mask
π 0	SigLIP + PaliGemma	Flow	连续 Chunk	隐式	统一数据/动作
π 0-FAST	PaliGemma	FAST Token	AR Token	隐式	Tokenizer
π 0.5	PaliGemma + Expert	FAST + Flow	连续 Chunk	显式子任务	异构 Co-training
GR00T N1.7	Qwen3-VL/Cosmos + DiT	Flow	连续 Chunk	VLM 条件	Embodiment MLP

8.1 模型选型建议

场景	推荐路线	理由
单机器人、单任务、数据少	ACT / Diffusion Policy	训练和部署成本较低，动作质量强
多任务、固定本体、语言控制	OpenVLA / π 0 微调	可复用 VLM 语义和语言泛化
精细连续操作、动作多模态	π 0 / Flow-DiT	连续动作精度高、Chunk 生成自然
跨机器人、多本体	GR00T 类显式本体条件化	便于处理动作维度与物理语义差异
长时域开放任务	层级 VLA + Memory	需要显式子任务和任务状态管理

9. 数据、训练与闭环执行

9.1 统一轨迹格式

$$\tau = \{I_t^{1:n}, q_t, a_t, \ell, M_t, e\}_{t=1:T}$$

必须明确动作是关节绝对位置、关节增量、末端位姿、末端增量、速度还是力矩。动作定义不一致往往比模型容量不足更致命。

9.2 动作归一化

常用分位数归一化降低异常值影响：

$$\tilde{a}_d = 2(a_d - Q_{0.01,d}) / (Q_{0.99,d} - Q_{0.01,d}) - 1$$

9.3 数据混合

$$p(D_i) = w_i / \sum_j w_j$$

不能只按原始数据量采样，否则大数据集会淹没目标机器人数据、精细操作数据与高层标注。混合权重应同时考虑质量、相关性、本体覆盖和任务覆盖。

9.4 Action Horizon 与 Execution Horizon

- **Action Horizon**：模型一次预测多少步；
- **Execution Horizon**：实际执行多少步后重新观测和规划。

例如模型预测 50 步但只执行 10 步，可以在轨迹连贯性和闭环纠错之间折中。若控制频率为 f ，则 Chunk 时间长度为：

$$T_{\text{chunk}} = H / f$$

9.5 推荐部署链路



相机采集、VLA GPU 推理和机器人控制宜解耦。机器人本地保持高频控制和安全逻辑，GPU 服务器低频返回 Chunk；网络中断时机器人必须安全停止，而不是继续盲目执行过期动作。

10. 长时域推理、评估与安全

10.1 三种长时域路线

隐式端到端

总任务直接条件低层动作。系统简单，但容易遗忘任务进度。

显式层级

先预测子任务，再生成低层动作。可解释，但高层错误会限制低层。

外部 Planner + VLA

规划灵活并可接入工具和记忆，但 Planner 可能提出低层策略无法执行的步骤。

层级 + Memory

维护已完成步骤、物体位置和失败历史，是更完整的未来形态。

10.2 六维评估体系

维度	指标示例
任务	整任务成功率、子任务成功率、任务完成比例
语言	目标选择、属性约束、空间关系、否定指令
泛化	新实例、新类别、新背景、新布局、新本体
动作	平滑性、jerk、碰撞、抓取失败、重规划频率
长时域	重复步骤、遗忘、失败恢复、任务状态一致性
实时性	端到端延迟、控制频率、显存、功耗、吞吐

10.3 安全边界

$$a_{safe} = \text{SafetyFilter}(a_{VLA})$$

真实系统仍需关节限位、速度/加速度限制、工作空间约束、自碰撞与环境碰撞检测、人体距离约束、急停和通信看门狗。任何端到端策略都不应被视为安全控制器。

11. 当前瓶颈与未来趋势

11.1 四个核心瓶颈

1. **数据**：真实示范昂贵，失败恢复数据少，长任务标注成本高。
2. **动作语义**：不同本体即使维度相同，控制量物理意义也可能完全不同。
3. **记忆**：短上下文难以记住物体位置、已完成步骤和跨房间状态。
4. **安全与验证**：开放模型输出难以给出形式化可靠性保证。

11.2 发展方向

- **层级具身 Agent**：Reasoning、Memory、World Model、VLA 和安全控制协同。
- **多传感器 VLA**：融合深度、触觉、力、音频、电机电流和点云。
- **交互学习**：利用失败、语言纠正、人类偏好、在线 RL 和自主探索。
- **数据组合定律**：研究数据比例、知识共享边界与跨域负迁移，而非只扩大模型。
- **高效部署**：KV Cache、少步 Flow、量化、异步 Chunk、端云协同和专用加速。

12. 总结：一条清晰的技术演进主线

1. **ACT 解决动作序列问题**：从单步回归走向 Action Chunk 与闭环聚合。
2. **RT-1 解决序列统一问题**：将动作离散化并引入 Transformer 自回归。
3. **现代 VLA 解决语义迁移问题**：利用预训练 VLM 将网页视觉语言知识迁移到控制。
4. **$\pi 0$ 与 GR00T 解决连续动作问题**：通过 Action Expert 和 Flow Matching 生成高质量 Chunk。
5. **$\pi 0.5$ 解决开放世界与长时域问题**：以异构 Co-training、混合动作表示和语义子任务实现泛化。

VLA = 语义主干 × 动作表示 × 数据配方 × 闭环系统

下一代系统将不只是单一 VLA，而是具备推理、记忆、世界状态、交互学习和安全约束的具身 Agent：

Embodied Agent = Reasoning + Memory + World Model + VLA Policy + Safety Controller

最终判断：VLA 不是具身智能的终点，而是通用多模态认知与真实物理行动之间最关键的接口。

建议讨论问题

- 什么时候应该选动作 Token，什么时候应该选 Flow？
- 跨本体泛化的主要矛盾是模型、数据，还是动作空间定义？
- 长时域任务应由统一模型隐式完成，还是显式引入层级与记忆？
- 机器人数据和网页数据分别应该训练哪些能力，如何避免负迁移？

报告依据 Mobile ALOHA、 $\pi 0.5$ 论文材料，以及工作区 ACT、RT-1、openpi 和 Isaac-GR00T 开源实现整理。具体论文数值、训练配比和产品级模型细节应以原论文及官方发布为准。